서울시 업무추진비 분석

https://opengov.seoul.go.kr/expense

https://github.com/seoul-opengov/opengov

0. 한글폰트 설치 후 진행

1) 한글 폰트 설치

- 설치 후 '런타임 다시 시작'

```
!apt-get update
!apt-get install -y fonts-nanum
!fc-cache -fv
!rm ~/.cache/matplotlib -rf
```

```
Ign:1 https://developer.download.nvidia.com/compute/cuda/repos/ubuntu1804/x86_64  InRelease
Get:2 http://security.ubuntu.com/ubuntu bionic-security InRelease [88.7 kB]
Get:3 http://ppa.launchpad.net/c2d4u.team/c2d4u4.0+/ubuntu bionic InRelease [15.9 kB]
Hit:4 http://archive.ubuntu.com/ubuntu bionic InRelease
Ign:5 https://developer.download.nvidia.com/compute/machine-learning/repos/ubuntu1804/x86_64
Hit:6 https://developer.download.nvidia.com/compute/cuda/repos/ubuntu1804/x86_64  Release
Hit:7 https://developer.download.nvidia.com/compute/machine-learning/repos/ubuntu1804/x86_64
Get:8 https://cloud.r-project.org/bin/linux/ubuntu bionic-cran40/ InRelease [3,626 B]
Get:9 http://archive.ubuntu.com/ubuntu bionic-updates InRelease [88.7 kB]
Hit:10 http://ppa.launchpad.net/cran/libgit2/ubuntu bionic InRelease
Hit:11 http://ppa.launchpad.net/graphics-drivers/ppa/ubuntu bionic InRelease
Get:12 http://archive.ubuntu.com/ubuntu bionic-backports InRelease [74.6 kB]
Get:13 http://ppa.launchpad.net/c2d4u.team/c2d4u4.0+/ubuntu bionic/main Sources [1,733 kB]
Get:16 http://ppa.launchpad.net/c2d4u.team/c2d4u4.0+/ubuntu bionic/main amd64 Packages [887 k
Get:17 http://security.ubuntu.com/ubuntu bionic-security/universe amd64 Packages [1,391 kB]
Get:18 http://archive.ubuntu.com/ubuntu bionic-updates/main amd64 Packages [2,360 kB]
Get:19 http://security.ubuntu.com/ubuntu bionic-security/main amd64 Packages [1,929 kB]
Get:20 http://archive.ubuntu.com/ubuntu bionic-updates/universe amd64 Packages [2,163 kB]
Fetched 10.7 MB in 3s (3,149 kB/s)
Reading package lists... Done
Reading package lists... Done
Building dependency tree
Reading state information... Done
The following NEW packages will be installed:
  fonts-nanum
0 upgraded, 1 newly installed, 0 to remove and 31 not upgraded.
Need to get 9,604 kB of archives.
After this operation, 29.5 MB of additional disk space will be used.
Get:1 http://archive.ubuntu.com/ubuntu bionic/universe amd64 fonts-nanum all 20170925-1 [9,6C
Fetched 9,604 kB in 1s (6,824 kB/s)
Selecting previously unselected package fonts-nanum.
(Reading database ... 146442 files and directories currently installed.)
```

```
Preparing to unpack .../fonts-nanum_20170925-1_all.deb ...
Unpacking fonts-nanum (20170925-1) ...
Setting up fonts-nanum (20170925-1) ...
Processing triggers for fontconfig (2.12.6-0ubuntu2) ...
/usr/share/fonts: caching, new cache contents: 0 fonts, 1 dirs
/usr/share/fonts/truetype: caching, new cache contents: 0 fonts, 3 dirs
/usr/share/fonts/truetype/humor-sans: caching, new cache contents: 1 fonts, 0 dirs
/usr/share/fonts/truetype/liberation: caching, new cache contents: 16 fonts, 0 dirs
/usr/share/fonts/truetype/nanum: caching, new cache contents: 10 fonts, 0 dirs
/usr/local/share/fonts: caching, new cache contents: 0 fonts, 0 dirs
/root/.local/share/fonts: skipping, no such directory
/root/.fonts: skipping, no such directory
/var/cache/fontconfig: cleaning cache directory
/root/.cache/fontconfig: not cleaning non-existent cache directory
/root/.fontconfig: not cleaning non-existent cache directory
fc-cache: succeeded
```

2) 한글 폰트 사용

```
import matplotlib as mpl
import matplotlib.pyplot as plt

mpl.rcParams['axes.unicode_minus'] = False

plt.rc('font', family='NanumBarunGothic')
```

I. 데이터 수집

```
import warnings
warnings.filterwarnings('ignore')
```

1) 파일 다운로드 함수 정의

- 1. github 경로 지정
- 2. 다운로드 폴더 지정
- 3. 다운로드 폴더 확인 또는 생성
- 4. 1월 ~ 12월 업무추진비 파일 다운로드

```
import requests
import os
import pathlib

def get_seoul_expense_list(extension, year, data_folder):

    # 01
```

```
    expense_list_year_url = 'https://github.com/seoul-opengov/opengov/raw/master/expense_list' + st

    # 02
    expense_list_year_dir = data_folder + str(year) + '/'

    # 03
    if(os.path.isdir(expense_list_year_dir)):
        print("폴더({0})가 존재합니다. {0}년 데이터의 다운로드를 시작합니다.".format(year))
    else:
        print("폴더({0})를 생성했습니다. {0}년 데이터의 다운로드를 시작합니다.".format(year))
        pathlib.Path(expense_list_year_dir).mkdir(parents = True, exist_ok = True)

    # 04
    for k in range(12):
        file_name = '{0}{1:02d}_expense_list.{2}'.format(year, k+1, extension)
        url = expense_list_year_url + file_name
        print(url)
        r = requests.get(url)
        with open(expense_list_year_dir + file_name, 'wb') as f:
            f.write(r.content)
```

2) 함수 실행 옵션

- 파일 타입 지정
- 연도 지정(2017~2019)
- 폴더 지정

```
extension = "csv"

years = [2017, 2018, 2019]

data_folder = 'data_folder_'
```

3) 파일 다운로드 함수 실행

```
for year in years:
  get_seoul_expense_list(extension, year, data_folder)
```

```
폴더(2017)를 생성했습니다. 2017년 데이터의 다운로드를 시작합니다.
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201701_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201702_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201703_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201704_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201705_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201706_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201707_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201708_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201709_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201710_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201711_expense_list.csv
```

https://github.com/seoul-opengov/opengov/raw/master/expense_list2017/201712_expense_list.csv
폴더(2018)를 생성했습니다. 2018년 데이터의 다운로드를 시작합니다.
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201801_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201802_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201803_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201804_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201805_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201806_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201807_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201808_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201809_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201810_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201811_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2018/201812_expense_list.csv
폴더(2019)를 생성했습니다. 2019년 데이터의 다운로드를 시작합니다.
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201901_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201902_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201903_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201904_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201905_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201906_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201907_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201908_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201909_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201910_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201911_expense_list.csv
https://github.com/seoul-opengov/opengov/raw/master/expense_list2019/201912_expense_list.csv

4) 다운로드 결과 확인

```
!ls -l data_folder_*
```

```
data_folder_2017:
total 27016
-rw-r--r-- 1 root root 2101932 Feb 23 01:46 201701_expense_list.csv
-rw-r--r-- 1 root root 2191463 Feb 23 01:46 201702_expense_list.csv
-rw-r--r-- 1 root root 2320233 Feb 23 01:46 201703_expense_list.csv
-rw-r--r-- 1 root root 2064545 Feb 23 01:46 201704_expense_list.csv
-rw-r--r-- 1 root root 2072997 Feb 23 01:46 201705_expense_list.csv
-rw-r--r-- 1 root root 2436396 Feb 23 01:46 201706_expense_list.csv
-rw-r--r-- 1 root root 2274618 Feb 23 01:46 201707_expense_list.csv
-rw-r--r-- 1 root root 2271758 Feb 23 01:46 201708_expense_list.csv
-rw-r--r-- 1 root root 2297135 Feb 23 01:46 201709_expense_list.csv
-rw-r--r-- 1 root root 2043312 Feb 23 01:46 201710_expense_list.csv
-rw-r--r-- 1 root root 2600188 Feb 23 01:46 201711_expense_list.csv
-rw-r--r-- 1 root root 2962735 Feb 23 01:46 201712_expense_list.csv

data_folder_2018:
total 28672
-rw-r--r-- 1 root root 2384105 Feb 23 01:46 201801_expense_list.csv
-rw-r--r-- 1 root root 2140712 Feb 23 01:46 201802_expense_list.csv
-rw-r--r-- 1 root root 2341018 Feb 23 01:46 201803_expense_list.csv
-rw-r--r-- 1 root root 2371427 Feb 23 01:46 201804_expense_list.csv
-rw-r--r-- 1 root root 2174724 Feb 23 01:46 201805_expense_list.csv
-rw-r--r-- 1 root root 2200840 Feb 23 01:46 201806_expense_list.csv
-rw-r--r-- 1 root root 2523642 Feb 23 01:46 201807_expense_list.csv
-rw-r--r-- 1 root root 2374994 Feb 23 01:46 201808_expense_list.csv
```

```
-rw-r--r-- 1 root root 2127882 Feb 23 01:46 201809_expense_list.csv
-rw-r--r-- 1 root root 2629462 Feb 23 01:46 201810_expense_list.csv
-rw-r--r-- 1 root root 2912043 Feb 23 01:46 201811_expense_list.csv
-rw-r--r-- 1 root root 3158601 Feb 23 01:46 201812_expense_list.csv

data_folder_2019:
total 30228
-rw-r--r-- 1 root root 2567789 Feb 23 01:46 201901_expense_list.csv
-rw-r--r-- 1 root root 2254140 Feb 23 01:46 201902_expense_list.csv
-rw-r--r-- 1 root root 2491410 Feb 23 01:46 201903_expense_list.csv
-rw-r--r-- 1 root root 2609914 Feb 23 01:46 201904_expense_list.csv
-rw-r--r-- 1 root root 2396247 Feb 23 01:46 201905_expense_list.csv
-rw-r--r-- 1 root root 2360821 Feb 23 01:46 201906_expense_list.csv
-rw-r--r-- 1 root root 2716107 Feb 23 01:46 201907_expense_list.csv
-rw-r--r-- 1 root root 2371337 Feb 23 01:46 201908_expense_list.csv
-rw-r--r-- 1 root root 2366976 Feb 23 01:46 201909_expense_list.csv
-rw-r--r-- 1 root root 2742090 Feb 23 01:46 201910_expense_list.csv
-rw-r--r-- 1 root root 2747034 Feb 23 01:46 201911_expense_list.csv
-rw-r--r-- 1 root root 3301721 Feb 23 01:46 201912_expense_list.csv
```

II. 데이터 전처리

1) 파일 구조 및 정보 확인

- 파일 한 개 사용

```
import pandas as pd

df = pd.read_csv('data_folder_2017/201701_expense_list.csv')

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5517 entries, 0 to 5516
Data columns (total 20 columns):
 #   Column             Non-Null Count  Dtype  
---  ------             --------------  -----  
 0   nid                5517 non-null   int64  
 1   title              5517 non-null   object 
 2   url                5517 non-null   object 
 3   dept_nm_lvl_1      5517 non-null   object 
 4   dept_nm_lvl_2      5517 non-null   object 
 5   dept_nm_lvl_3      4842 non-null   object 
 6   dept_nm_lvl_4      1350 non-null   object 
 7   dept_nm_lvl_5      252 non-null    object 
 8   exec_yr            5517 non-null   int64  
 9   exec_month         5517 non-null   int64  
 10  expense_budget     274 non-null    float64
 11  expense_execution  202 non-null    float64
 12  category           115 non-null    object 
 13  dept_nm_full       5517 non-null   object 
 14  exec_dt            5517 non-null   object 
 15  exec_loc           5467 non-null   object 
 16  exec_purpose       5516 non-null   object 
```

```
 17  target_nm          5486 non-null   object
 18  payment_method     5514 non-null   object
 19  exec_amount        5517 non-null   int64
dtypes: float64(2), int64(4), object(14)
memory usage: 862.2+ KB
```

2) 함수 정의

- 열(Column) 이름 확인

```
df.columns
```

```
Index(['nid', 'title', 'url', 'dept_nm_lvl_1', 'dept_nm_lvl_2',
       'dept_nm_lvl_3', 'dept_nm_lvl_4', 'dept_nm_lvl_5', 'exec_yr',
       'exec_month', 'expense_budget', 'expense_execution', 'category',
       'dept_nm_full', 'exec_dt', 'exec_loc', 'exec_purpose', 'target_nm',
       'payment_method', 'exec_amount'],
      dtype='object')
```

- 열(Column) 이름 변경 함수

```
def change_csv_file_first_line_value(old_file_name, new_file_name):
    # 읽기 모드 열기
    with open(old_file_name, encoding = 'utf-8') as f:
        # 한 줄씩 lines 리스트의 각 요소에 할당
        lines = f.read().splitlines()

    # 변경할 열(Column) 이름 지정
    lines[0] = 'nid,제목,url,부서레벨1,부서레벨2,부서레벨3,부서레벨4,W
부서레벨5,집행연도,집행월,예산,집행,구분,부서명,W
집행일시,집행장소,집행목적,대상인원,결제방법,집행금액'

    # 쓰기 모드 열기
    with open(new_file_name, 'w', encoding = 'utf-8') as f:
        # 리스트 각 요소 개행문자(Wn)로 연결해서 파일 저장
        f.write('Wn'.join(lines))
```

- '_new' 추가한 새파일 저장 함수

```
# 인자: 연도, 데이터 파일이 있는 폴더
def change_year_csv_file_first_line_value(year, data_folder):

    # 파일 폴더 지정
    expense_list_year_dir = data_folder + str(year) + '/'

    # 확장자 이름
    extension = 'csv'

    # 지정한 폴더에 있는 월별 업무추진비 파일에서 첫 번째 줄의 열 이름을 변경
    for k in range(12):
        # 기존 파일 이름
```

```
        # 기존 파일 이름
        old_file_name = expense_list_year_dir + '{0}{1:02d}_expense_list.{2}'.format(year, k+1, ext

        # 새파일 이름
        new_file_name = expense_list_year_dir + '{0}{1:02d}_expense_list_new.{2}'.format(year, k+1,

        # 열(Column) 이름 변경 함수
        change_csv_file_first_line_value(old_file_name, new_file_name)
```

3) 함수 적용

```
data_folder = 'data_folder_'

years = [2017, 2018, 2019]

for year in years:
    print("{}년 데이터의 첫 번째 줄의 열 이름을 변경해서 새 파일에 저장합니다.".format(year))
    change_year_csv_file_first_line_value(year, data_folder)

print("모든 데이터의 첫 번째 줄의 열 이름을 변경해서 새 파일로 저장했습니다.")
```

```
2017년 데이터의 첫 번째 줄의 열 이름을 변경해서 새 파일에 저장합니다.
2018년 데이터의 첫 번째 줄의 열 이름을 변경해서 새 파일에 저장합니다.
2019년 데이터의 첫 번째 줄의 열 이름을 변경해서 새 파일에 저장합니다.
모든 데이터의 첫 번째 줄의 열 이름을 변경해서 새 파일로 저장했습니다.
```

- 새파일 생성 확인

```
!ls -l data_folder_*/*new.csv
```

```
-rw-r--r-- 1 root root 2101920 Feb 23 01:47 data_folder_2017/201701_expense_list_new.csv
-rw-r--r-- 1 root root 2191451 Feb 23 01:47 data_folder_2017/201702_expense_list_new.csv
-rw-r--r-- 1 root root 2320221 Feb 23 01:47 data_folder_2017/201703_expense_list_new.csv
-rw-r--r-- 1 root root 2064533 Feb 23 01:47 data_folder_2017/201704_expense_list_new.csv
-rw-r--r-- 1 root root 2072985 Feb 23 01:47 data_folder_2017/201705_expense_list_new.csv
-rw-r--r-- 1 root root 2436384 Feb 23 01:47 data_folder_2017/201706_expense_list_new.csv
-rw-r--r-- 1 root root 2274606 Feb 23 01:47 data_folder_2017/201707_expense_list_new.csv
-rw-r--r-- 1 root root 2271746 Feb 23 01:47 data_folder_2017/201708_expense_list_new.csv
-rw-r--r-- 1 root root 2297123 Feb 23 01:47 data_folder_2017/201709_expense_list_new.csv
-rw-r--r-- 1 root root 2043300 Feb 23 01:47 data_folder_2017/201710_expense_list_new.csv
-rw-r--r-- 1 root root 2600176 Feb 23 01:47 data_folder_2017/201711_expense_list_new.csv
-rw-r--r-- 1 root root 2962723 Feb 23 01:47 data_folder_2017/201712_expense_list_new.csv
-rw-r--r-- 1 root root 2384093 Feb 23 01:47 data_folder_2018/201801_expense_list_new.csv
-rw-r--r-- 1 root root 2140700 Feb 23 01:47 data_folder_2018/201802_expense_list_new.csv
-rw-r--r-- 1 root root 2341006 Feb 23 01:47 data_folder_2018/201803_expense_list_new.csv
-rw-r--r-- 1 root root 2371415 Feb 23 01:47 data_folder_2018/201804_expense_list_new.csv
-rw-r--r-- 1 root root 2174712 Feb 23 01:47 data_folder_2018/201805_expense_list_new.csv
-rw-r--r-- 1 root root 2200828 Feb 23 01:47 data_folder_2018/201806_expense_list_new.csv
-rw-r--r-- 1 root root 2523630 Feb 23 01:47 data_folder_2018/201807_expense_list_new.csv
-rw-r--r-- 1 root root 2374982 Feb 23 01:47 data_folder_2018/201808_expense_list_new.csv
-rw-r--r-- 1 root root 2127870 Feb 23 01:47 data_folder_2018/201809_expense_list_new.csv
-rw-r--r-- 1 root root 2629450 Feb 23 01:47 data_folder_2018/201810_expense_list_new.csv
-rw-r--r-- 1 root root 2912031 Feb 23 01:47 data_folder_2018/201811_expense_list_new.csv
-rw-r--r-- 1 root root 3158589 Feb 23 01:47 data_folder_2018/201812_expense_list_new.csv
```

```
-rw-r--r-- 1 root root 2567777 Feb 23 01:47 data_folder_2019/201901_expense_list_new.csv
-rw-r--r-- 1 root root 2254128 Feb 23 01:47 data_folder_2019/201902_expense_list_new.csv
-rw-r--r-- 1 root root 2491398 Feb 23 01:47 data_folder_2019/201903_expense_list_new.csv
-rw-r--r-- 1 root root 2609902 Feb 23 01:47 data_folder_2019/201904_expense_list_new.csv
-rw-r--r-- 1 root root 2396235 Feb 23 01:47 data_folder_2019/201905_expense_list_new.csv
-rw-r--r-- 1 root root 2360809 Feb 23 01:47 data_folder_2019/201906_expense_list_new.csv
-rw-r--r-- 1 root root 2716095 Feb 23 01:47 data_folder_2019/201907_expense_list_new.csv
-rw-r--r-- 1 root root 2371325 Feb 23 01:47 data_folder_2019/201908_expense_list_new.csv
-rw-r--r-- 1 root root 2366964 Feb 23 01:47 data_folder_2019/201909_expense_list_new.csv
-rw-r--r-- 1 root root 2742078 Feb 23 01:47 data_folder_2019/201910_expense_list_new.csv
-rw-r--r-- 1 root root 2747022 Feb 23 01:47 data_folder_2019/201911_expense_list_new.csv
-rw-r--r-- 1 root root 3301709 Feb 23 01:47 data_folder_2019/201912_expense_list_new.csv
```

- 열(Column) 이름 변경 확인

```
df_new = pd.read_csv('data_folder_2017/201701_expense_list_new.csv')

df.columns, df_new.columns
```

```
(Index(['nid', 'title', 'url', 'dept_nm_lvl_1', 'dept_nm_lvl_2',
        'dept_nm_lvl_3', 'dept_nm_lvl_4', 'dept_nm_lvl_5', 'exec_yr',
        'exec_month', 'expense_budget', 'expense_execution', 'category',
        'dept_nm_full', 'exec_dt', 'exec_loc', 'exec_purpose', 'target_nm',
        'payment_method', 'exec_amount'],
       dtype='object'),
 Index(['nid', '제목', 'url', '부서레벨1', '부서레벨2', '부서레벨3', '부서레벨4', '부서레벨5',
        '집행월', '예산', '집행', '구분', '부서명', '집행일시', '집행장소', '집행목적', '대상',
        '집행금액'],
       dtype='object'))
```

4) 결측치 확인

- .info( ) 적용

```
df_new.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5517 entries, 0 to 5516
Data columns (total 20 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   nid     5517 non-null   int64
 1   제목      5517 non-null   object
 2   url     5517 non-null   object
 3   부서레벨1   5517 non-null   object
 4   부서레벨2   5517 non-null   object
 5   부서레벨3   4842 non-null   object
 6   부서레벨4   1350 non-null   object
 7   부서레벨5   252 non-null    object
 8   집행연도    5517 non-null   int64
 9   집행월     5517 non-null   int64
 10  예산      274 non-null    float64
 11  집행      202 non-null    float64
 12  구분      115 non-null    object
```

```
 13  부서명     5517 non-null   object
 14  집행일시    5517 non-null   object
 15  집행장소    5467 non-null   object
 16  집행목적    5516 non-null   object
 17  대상인원    5486 non-null   object
 18  결제방법    5514 non-null   object
 19  집행금액    5517 non-null   int64
dtypes: float64(2), int64(4), object(14)
memory usage: 862.2+ KB
```

- isna( ) 적용
  - '부서레벨3', '부서레벨4', '부서레벨5', '예산', '집행', '구분'

```
df_new.isna().sum(axis = 0)
```

```
nid         0
제목          0
url         0
부서레벨1       0
부서레벨2       0
부서레벨3     675
부서레벨4    4167
부서레벨5    5265
집행연도        0
집행월         0
예산       5243
집행       5315
구분       5402
부서명         0
집행일시        0
집행장소       50
집행목적        1
대상인원       31
결제방법        3
집행금액        0
dtype: int64
```

5) 연도별 파일 통합

- 파일 통합 함수 정의

```
def select_columns_save_file(year, data_folder, drop_columns_list):

    expense_list_year_dir = data_folder + str(year) + '/'
    expense_list_tidy_file = "{}_expense_list_tidy.csv".format(year)
    df_year = pd.DataFrame()

    for k in range(12):
        # 새파일 이름 지정
        file_name = "{0}{1:02d}_expense_list_new.csv".format(year, k+1)

        # DtaFrame 형식으로 csv 데이터 불러오기
        df_month = pd.read_csv(expense_list_year_dir + file_name)
```

```
        # df_month 새로 추가해서 df_year에 다시 할당
        df_year = df_year.append(df_month, ignore_index = True)

    df_year_drop = df_year.drop(columns = drop_columns_list)
    new_file_name = expense_list_year_dir + expense_list_tidy_file
    df_year_drop.to_csv(new_file_name, index = False)

    print("==> {} 파일 생성".format(expense_list_tidy_file))
```

- 함수 실행 옵션

```
data_folder = 'data_folder_'

years = [2017, 2018, 2019]

drop_columns_list = ['nid', 'url', '부서레벨3', '부서레벨4', '부서레벨5', '예산', '집행', '구분']
```

- 파일 통합 함수 실행

```
for year in years:
    print("{}년 파일 통합중...".format(year))
    select_columns_save_file(year, data_folder, drop_columns_list)
print("파일 통합 완료.")
```

```
2017년 파일 통합중...
==> 2017_expense_list_tidy.csv 파일 생성
2018년 파일 통합중...
==> 2018_expense_list_tidy.csv 파일 생성
2019년 파일 통합중...
==> 2019_expense_list_tidy.csv 파일 생성
파일 통합 완료.
```

- 생성된 통합 파일 확인

```
!ls -l data_folder_*/*tidy*
```

```
-rw-r--r-- 1 root root 21435432 Feb 23 01:47 data_folder_2017/2017_expense_list_tidy.csv
-rw-r--r-- 1 root root 22940371 Feb 23 01:47 data_folder_2018/2018_expense_list_tidy.csv
-rw-r--r-- 1 root root 24385017 Feb 23 01:47 data_folder_2019/2019_expense_list_tidy.csv
```

- 2017 통합 파일 정보

```
df_2017 = pd.read_csv('data_folder_2017/2017_expense_list_tidy.csv')

df_2017.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 70132 entries, 0 to 70131
Data columns (total 12 columns):
```

```
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   제목      70132 non-null  object
 1   부서레벨1   70132 non-null  object
 2   부서레벨2   70074 non-null  object
 3   집행연도    70132 non-null  int64
 4   집행월     70132 non-null  int64
 5   부서명     70053 non-null  object
 6   집행일시    70132 non-null  object
 7   집행장소    69360 non-null  object
 8   집행목적    70110 non-null  object
 9   대상인원    69597 non-null  object
 10  결제방법    69929 non-null  object
 11  집행금액    70132 non-null  int64
dtypes: int64(3), object(9)
memory usage: 6.4+ MB
```

6) 전체 파일 통합

- DataFrame : df_expense_all

```
import pandas as pd
```

```
data_folder = 'data_folder_'

years = [2017, 2018, 2019]

df_expense_all = pd.DataFrame()


for year in years:
    expense_list_year_dir = data_folder + str(year) + '/'
    expense_list_tidy_file = "{}_expense_list_tidy.csv".format(year)

    path_file_name = expense_list_year_dir + expense_list_tidy_file

    df_expense = pd.read_csv(path_file_name)
    df_expense_all = df_expense_all.append(df_expense, ignore_index = True)
```

- 전체 통합 DataFrame 확인

```
df_expense_all.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 216557 entries, 0 to 216556
Data columns (total 12 columns):
 #   Column  Non-Null Count   Dtype
---  ------  --------------   -----
 0   제목      216557 non-null  object
 1   부서레벨1   216557 non-null  object
 2   부서레벨2   216273 non-null  object
 3   집행연도    216557 non-null  int64
 4   집행월     216557 non-null  int64
```

```
 5   부서명     216478 non-null  object
 6   집행일시    216557 non-null  object
 7   집행장소    214401 non-null  object
 8   집행목적    216535 non-null  object
 9   대상인원    215535 non-null  object
 10  결제방법    216354 non-null  object
 11  집행금액    216557 non-null  int64
dtypes: int64(3), object(9)
memory usage: 19.8+ MB
```

- 'seoulExpense.csv' 파일 저장

```
df_expense_all.to_csv('seoulExpense.csv')
```

III. 데이터 분석

1) 연도별 집행횟수

- 연도별 .value_count( )

```
year_trend = df_expense_all['집행연도'].value_counts()

year_trend
```

```
2019    74207
2018    72218
2017    70132
Name: 집행연도, dtype: int64
```

- 막대그래프 시각화

```
import matplotlib.pyplot as plt
import matplotlib

plt.figure(figsize = (10, 7))
plt.bar(year_trend.index, year_trend.values,
        tick_label = year_trend.index,
        width = 0.5)
plt.title("연도별 업무추진비 집행 횟수")
plt.xlabel("연도")
plt.ylabel("집행 횟수")
plt.show()
```

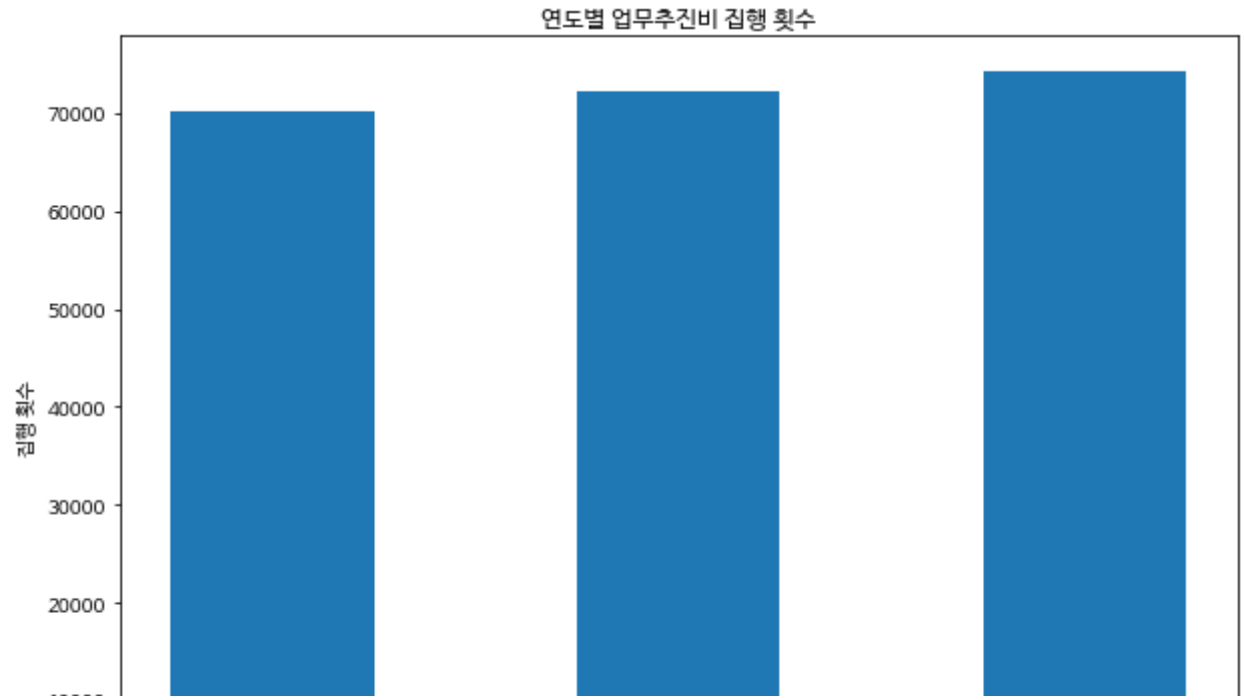

2) 연도별 집행금액

- 연도별 .pibot_table( )

```
year_total = pd.pivot_table(df_expense_all,
                            index = ['집행연도'],
                            values = ['집행금액'],
                            aggfunc = sum)

year_total
```

	집행금액
집행연도	
2017	9076941387
2018	9937556542
2019	10532330632

- 막대그래프 시각화

```
(year_total/100000000).plot.bar(rot = 25, figsize = (10, 7))
plt.ylabel('집행금액(억원)')
plt.show()
```

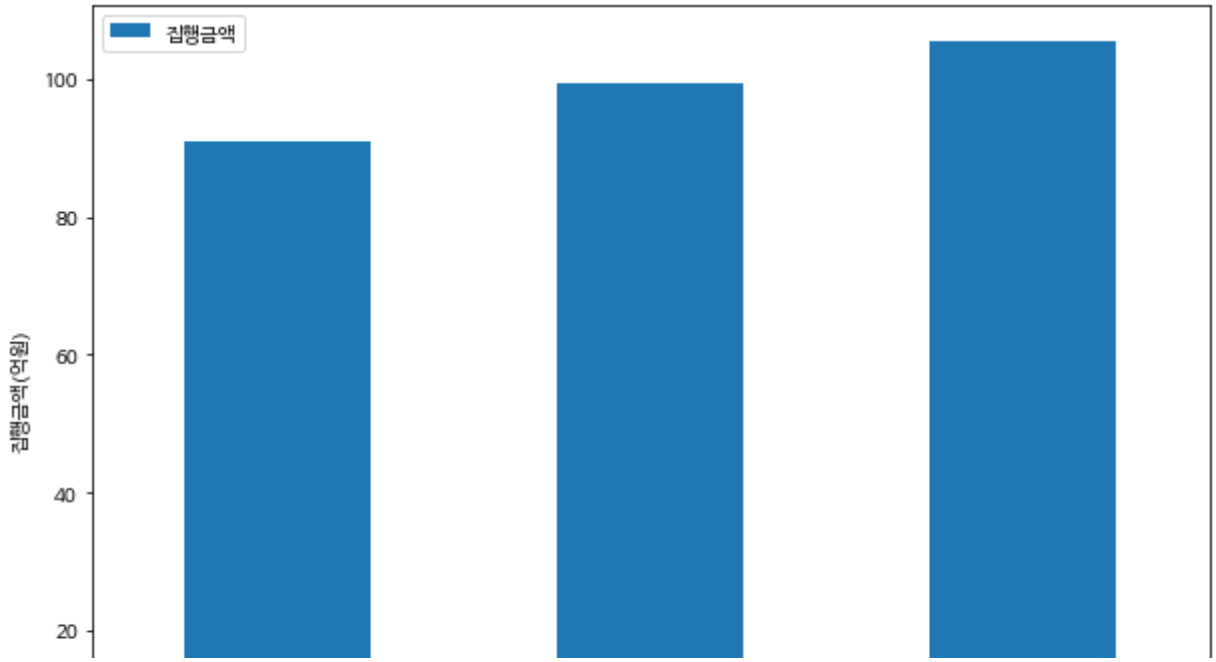

3) 월별 집행금액

- 월별 .pivot_table( )

```
month_total = pd.pivot_table(df_expense_all,
                             index = ['집행월'],
                             values = ['집행금액'],
                             aggfunc = sum)

month_total
```

집행월	집행금액
1	2328469179
2	2250971737
3	2314589911
4	2153704599
5	2063883588
6	2224855495
7	2372256669
8	2153716469
9	2417217365
10	2326108698
11	2719921484
12	4221133367

- 연별/월별 .pivot_table( )

```
year_month_total = pd.pivot_table(df_expense_all,
                                  index = ['집행월'],
                                  columns = ['집행연도'],
                                  values = ['집행금액'],
                                  aggfunc = sum)

year_month_total
```

	집행금액		
집행연도	2017	2018	2019
집행월			
1	710368860	735587570	882512749
2	712679864	769360005	768931868
3	737250454	761059010	816280447
4	635265805	703781418	814657376
5	647582378	669044701	747256509
6	758257342	690652154	775945999
7	701604626	788926477	881725566
8	661174850	730290532	762251087
9	806170700	769404957	841641708
10	637219943	827022975	861865780
11	843619171	960310221	915992092
12	1225747394	1532116522	1463269451

- 막대그래프 시각화

```
(year_month_total/100000000).plot.bar(rot = 0, figsize = (10, 7))
plt.ylabel('집행금액(억원)')
plt.title("업무추진비의 월별 집행금액")
plt.legend(['2017년', '2018년', '2019년'])
plt.show()
```

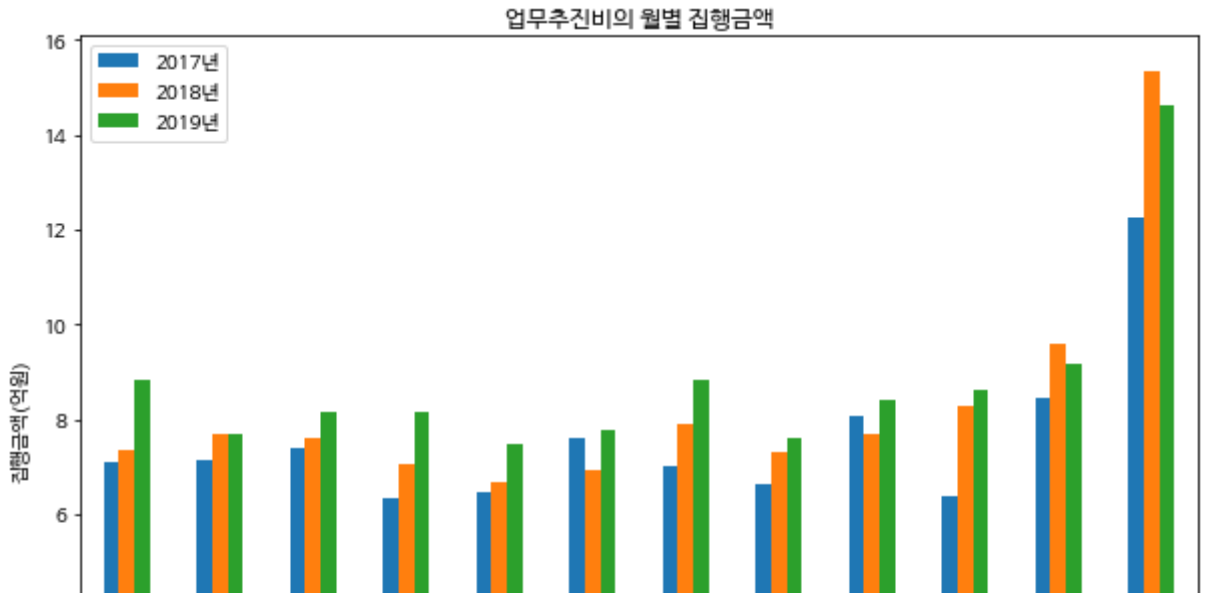

4) 부서별 집행금액

- 부서별_level1 .pivot_table( )

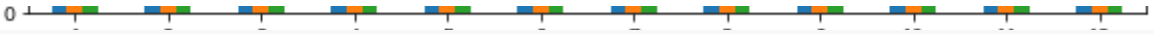


```
dept_level1_total = pd.pivot_table(df_expense_all,
                                   index = ['부서레벨1'],
                                   values = ['집행금액'],
                                   aggfunc = sum)

dept_level1_total
```

부서레벨1	집행금액
사업소	6552128899
서울시본청	16606242519
소방재난본부(소방서)	5147645293
의회사무처	1240811850

- 부서별_level2 .pivot_table( )

```
dept_level2_total = pd.pivot_table(df_expense_all,
                                   index = ['부서레벨2'],
                                   values = ['집행금액'],
                                   aggfunc = sum)

dept_level2_total
```

부서레벨2	집행금액
119특수구조단	119225100
감사위원회	343281170
강남소방서	229660520
강동소방서	188773330
강북소방서	167700000
...	...
행정2부시장	522277598
행정국	1320839804
행정자치위원회	57397750
행정자치전문위원실	38221340

- 집행금액별 오름차순 정렬

137 rows × 1 columns

```
dept_level2_total_top10 = dept_level2_total.sort_values(by = ['집행금액'], ascending = False)[0:10]

dept_level2_total_top10
```

부서레벨2	집행금액
상수도사업본부	2156404778
기획조정실	1572753168
행정국	1320839804
서울특별시장	955448760
시민소통기획관	923338423
도시기반시설본부	620669144
정무부시장	581806882
행정1부시장	540457390
행정2부시장	522277598
기후환경본부	515222890

- 막대그래프 시각화

```
(dept_level2_total_top10/100000000).plot.bar(rot = 45, figsize = (10, 7))
plt.ylabel('집행금액(억원)')
plt.title("업무추진비 집행금액이 높은 상위 10개 부서")
plt.show()
```

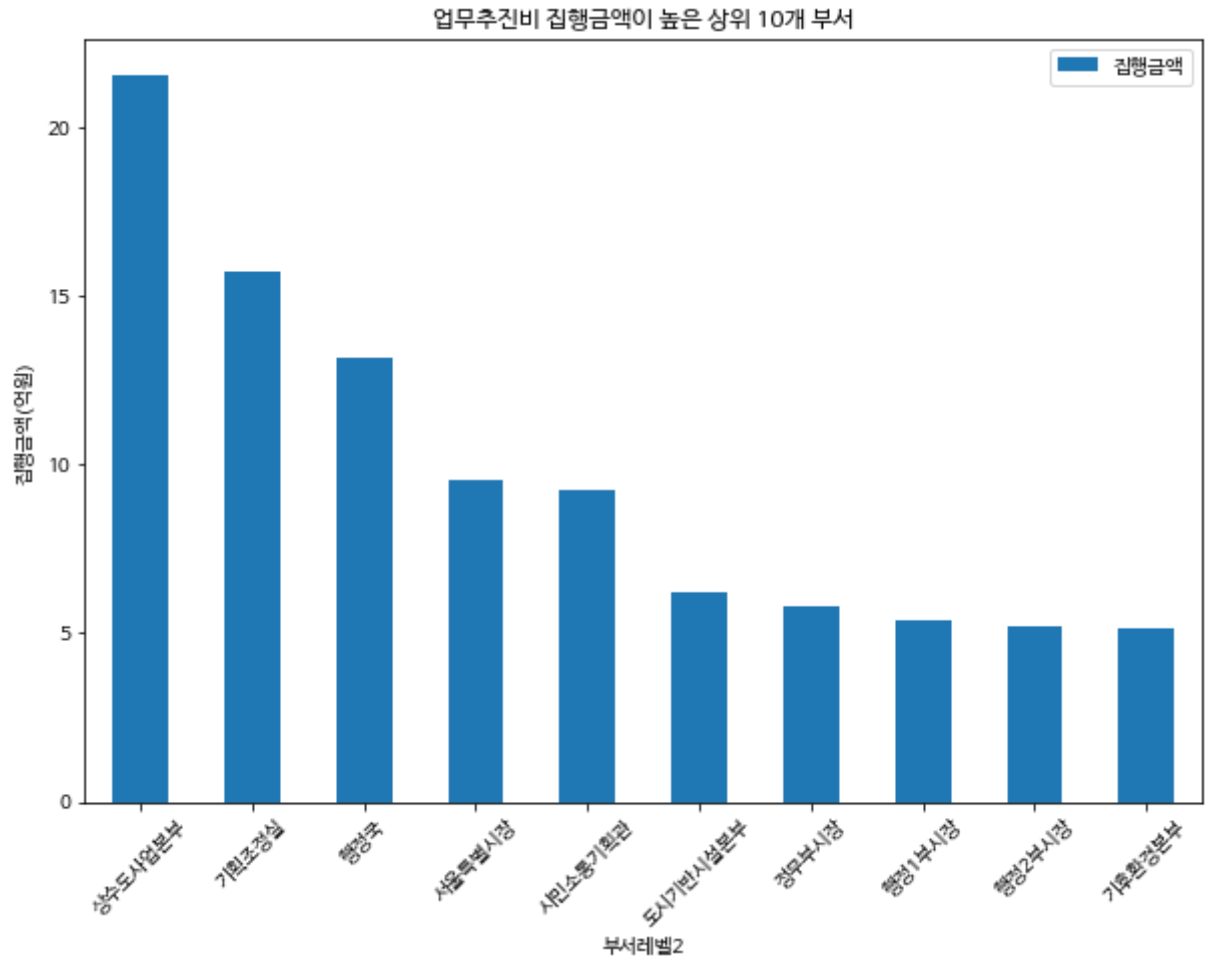

- 워드클라우드 시각화

```
from wordcloud import WordCloud

korean_font_path = '/usr/share/fonts/truetype/nanum/NanumBarunGothic.ttf'

wc = WordCloud(font_path = korean_font_path,
               background_color='white',
               width = 800, height = 600)

frequencies = dept_level2_total['집행금액']

wordcloud_image = wc.generate_from_frequencies(frequencies)

plt.figure(figsize=(14, 9))
plt.axis('off')
plt.imshow(wordcloud_image, interpolation = 'bilinear')
plt.show()
```

5) 요일별 집행횟수

- 시간정보 확인

```
df_expense_all['집행일시'].values
```

```
array(['2017-01-26 13:10', '2017-01-25 22:41', '2017-01-24 12:35', ...,
       '2019-12-19 11:34', '2019-12-16 12:39', '2019-12-03 17:35'],
      dtype=object)
```

- pd.to_datetime( ) 변환

```
expense_date_time = pd.to_datetime(df_expense_all['집행일시'])

expense_date_time.values
```

```
array(['2017-01-26T13:10:00.000000000', '2017-01-25T22:41:00.000000000',
       '2017-01-24T12:35:00.000000000', ...,
       '2019-12-19T11:34:00.000000000', '2019-12-16T12:39:00.000000000',
       '2019-12-03T17:35:00.000000000'], dtype='datetime64[ns]')
```

- '집행일시_요일' 행(Column) 추가
  - dt.weekday : 날짜를 요일로 변환

```
week_day_name = ['월', '화', '수', '목', '금', '토', '일']

df_expense_all['집행일시_요일'] = [week_day_name[weekday] for weekday in expense_date_time.dt.weekd
```

- 추가 정보 확인

```
df_expense_all.head()
```

	제목	부서레벨1	부서레벨2	집행연도	집행월	부서명	집행일시	집행장소	집행목적	대상인원	결제방법	집행금액	집행일시_요일
0	2017년 1월 장애인복지 정책과 업무 추진비 집행 내역	서울시본청	복지본부	2017	1	복지본부 장애인복지정책과	2017-01-26 13:10	동해일식 (중구 무교동)	기본소득과 장애인 복지 논의 간담회	장애인복지정책팀장 외 2명	카드	76000	목
1	2017년 1월 장애인복지 정책과 업무	서울시	복지	2017	1	복지본부 장애	2017-01-25	김앤장 (중구	장애인단체 활동지	장애인복지정	카	102000	수

- 요일별 집행횟수 확인

```
expense_weekday = df_expense_all['집행일시_요일'].value_counts()

expense_weekday
```

```
목    45683
화    43812
수    42343
금    41381
월    39498
토     2238
일     1602
Name: 집행일시_요일, dtype: int64
```

- 요일순 정렬 : .reindex( )

```
expense_weekday = expense_weekday.reindex(index = week_day_name)

expense_weekday
```

```
월    39498
화    43812
수    42343
목    45683
금    41381
토     2238
일     1602
Name: 집행일시_요일, dtype: int64
```

- 막대그래프 시각화

```
expense_weekday.plot.bar(rot = 0, figsize = (10, 7))
plt.title("요일별 업무추진비 집행 횟수")
plt.xlabel("요일")
plt.ylabel("집행 횟수")
plt.show()
```

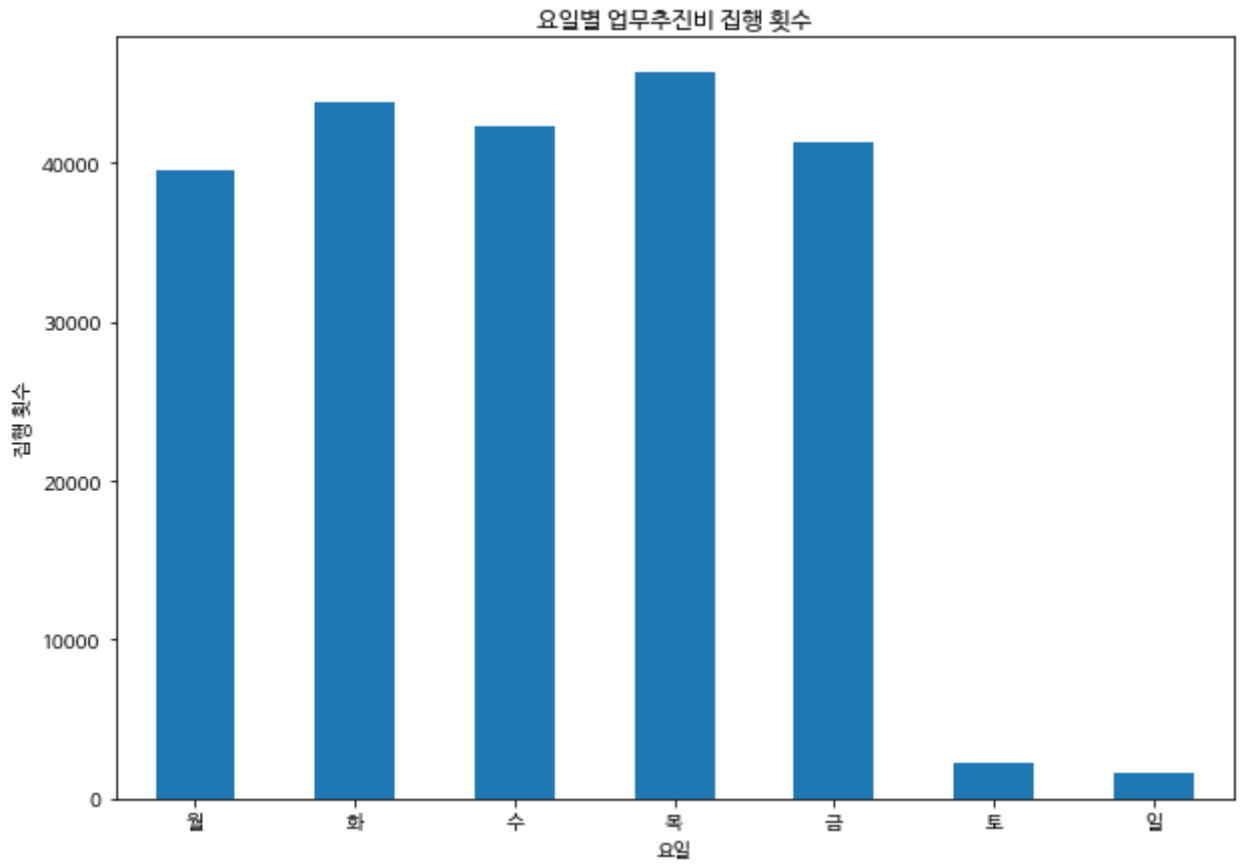

6) 시간별 집행횟수

- '집행일시_시간' 행(Column) 추가

- dt.hour : 날짜를 시간으로 변환

```
df_expense_all['집행일시_시간'] = [hour for hour in expense_date_time.dt.hour]
```

- 추가 정보 확인

```
df_expense_all.head()
```

	제목	부서레벨1	부서레벨2	집행연도	집행월	부서명	집행일시	집행장소	집행목적	대상인원	결제방법	집행금액	집행일시_요일	집행일시_시간
0	2017년 1월 장애인복지정책과 업무추진비 집행내역	서울시본청	복지본부	2017	1	복지본부 장애인복지정책과	2017-01-26 13:10	동해일식(중구 무교동)	기본소득과 장애인복지 논의간담회	장애인복지정책팀장 외 2명	카드	76000	목	13
	2017년 1월	서	복			복지 본부		김앤장		장애인복				

- 시간별 집행횟수 확인

```
expense_hour_num = df_expense_all['집행일시_시간'].value_counts()

expense_hour_num
```

```
12    87518
20    23013
```

```
13    20990
19    16766
21    12210
11     8356
14     8311
15     7168
10     5824
18     5783
16     5169
0      4919
9      3486
17     2889
22     2563
8       875
7       412
23      128
1        44
6        42
3        27
4        26
5        19
2        19
Name: 집행일시_시간, dtype: int64
```

- 시간순 정렬 : .reindex( )
  - 8시 기준

```
work_hour = [ (k+8)%24 for k in range(24)]
expense_hour_num = expense_hour_num.reindex(index = work_hour)

expense_hour_num
```

```
8       875
9      3486
10     5824
11     8356
12    87518
13    20990
14     8311
15     7168
16     5169
17     2889
18     5783
19    16766
20    23013
21    12210
22     2563
23      128
0      4919
1        44
2        19
3        27
4        26
5        19
6        42
7       412
Name: 집행일시_시간, dtype: int64
```

- 막대그래프 시각화

```
expense_hour_num.plot.bar(rot = 0, figsize = (10, 7))
plt.title("시간별 업무추진비 집행 횟수")
plt.xlabel("집행 시간")
plt.ylabel("집행 횟수")
plt.show()
```

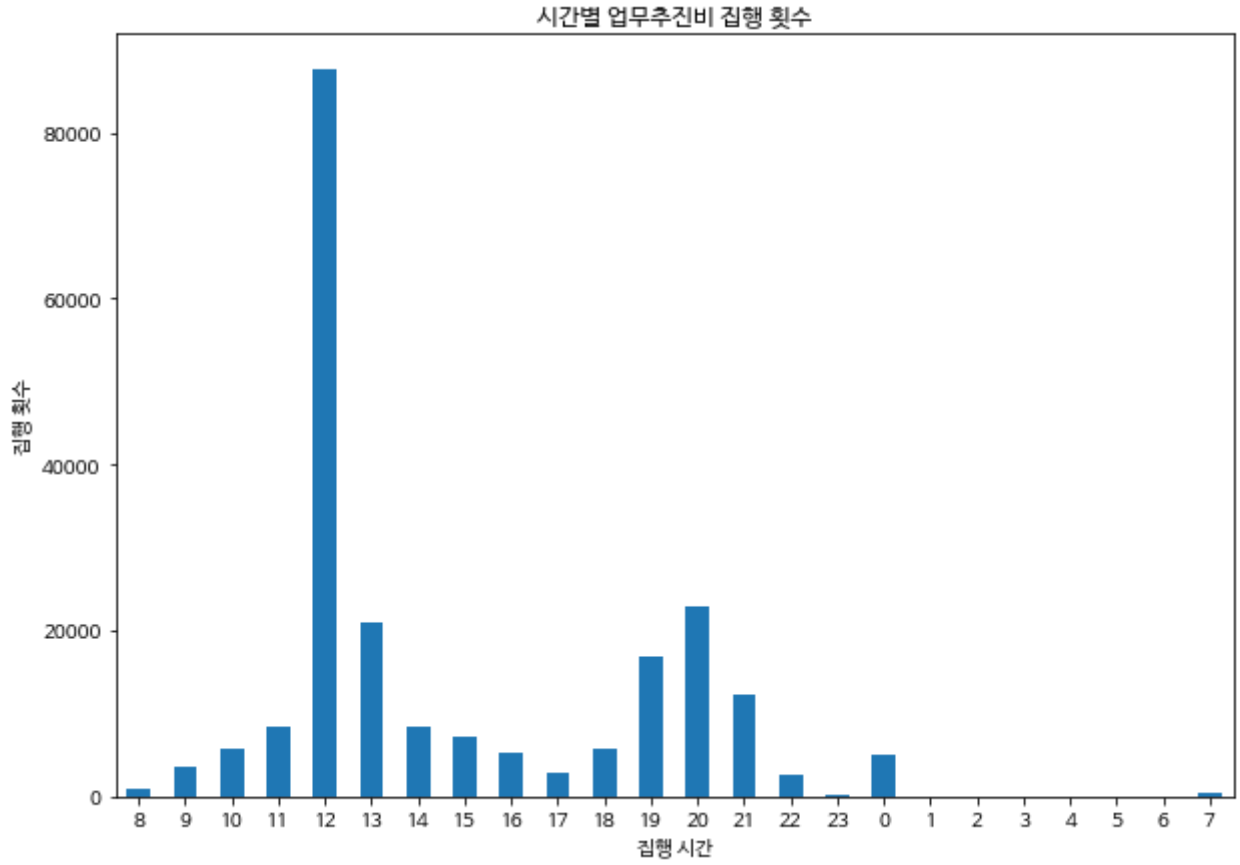

7) 시간별 집행금액

- 시간별 .pivot_table( )

```
expense_hour_total = pd.pivot_table(df_expense_all,
                                    index = ['집행일시_시간'],
                                    values = ['집행금액'],
                                    aggfunc = sum)

expense_hour_total.head()
```

집행일시_시간	집행금액
0	842523116
2	2265190

- 막대그래프 시각화

```
expense_hour_total = expense_hour_total.reindex(index = work_hour)

(expense_hour_total/100000000).plot.bar(rot = 0, figsize = (10, 7))
plt.ylabel('집행금액(억원)')
plt.title("시간별대 업무추진비 집행금액")
plt.show()
```

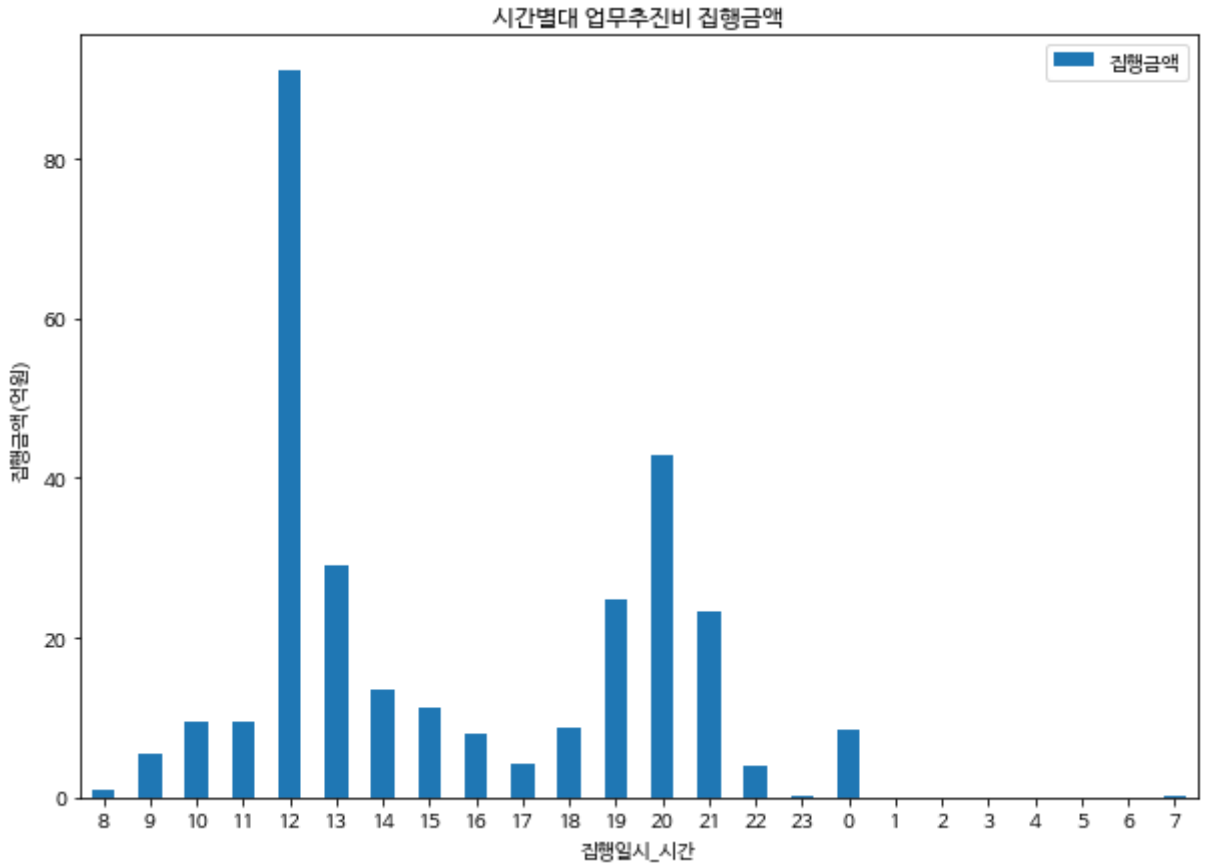

#

#

#

The End

#

#

#