▼ Customer Segmentation - 고객 군집

```
import warnings
warnings.filterwarnings('ignore')
```

I. Import Packages and Google Drive Mount

→ 1) Import Packages

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
```

→ 2) Google Drive Mount

• 'Online_Retail.zip' 파일을 구글드라이브에 업로드 후 진행

```
from google.colab import drive
drive.mount('<u>/content/drive</u>')
```

Mounted at /content/drive

• 마운트 결과 확인

```
!Is -I '/content/drive/My Drive/Colab Notebooks/datasets/Online_Retail.zip'
-rw----- 1 root root 22824989 Mar 7 07:09 '/content/drive/My Drive/Colab Notebooks/dataset
```

II. Data Preprocessing

→ 1) Unzip 'Online_Retail.zip'

• Colab 파일시스템에 'Online_Retail.csv' 파일 생성

!|s -|

Archive: /content/drive/My Drive/Colab Notebooks/datasets/Online_Retail.zip inflating: Online_Retail.xlsx

• Online_Retail.zip 파일 확인

```
total 23168
drwx----- 5 root root 4096 Mar 10 05:40 drive
-rw-r--r-- 1 root root 23715344 Mar 7 16:08 Online_Retail.xlsx
```

drwxr-xr-x 1 root root 4096 Mar 5 14:37 sample_data

▼ 2) 데이터 읽어오기

pandas DataFrame

```
%%time

DF = pd.read_excel('Online_Retail.xlsx')

DF.info()
```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 541909 entries, 0 to 541908
Data columns (total 8 columns):

#	Column	Non-Null Count	Dtype		
0	InvoiceNo	541909 non-null	object		
1	StockCode	541909 non-null	object		
2	Description	540455 non-null	object		
3	Quantity	541909 non-null	int64		
4	InvoiceDate	541909 non-null	datetime64[ns]		
5	UnitPrice	541909 non-null	float64		
6	CustomerID	406829 non-null	float64		
7	Country	541909 non-null	object		
dtypes: datetime64[ns](1), float64(2), int64(1), object(4)					
memory usage: 33.1+ MB					
CPU times: user 38.5 s, sys: 392 ms, total: 38.9 s					
Wall time: 38.9 s					

▼ 3) 데이터 설명

• InvoiceNo: 주문 번호, 'C' 시작은 주문취소

• StockCode : 제품 코드(Item Code)

Description : 제품 설명
Quantity : 주문 건수
InvoiceDate : 주문 날짜

• UnitPrice : 제품 단가

• CustomerID : 고객번호

• Country: 국가명(주문 고객 국적)

DF.head()

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	Cus
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	2010-12-01 08:26:00	2.55	
1	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00	3.39	
2	536365	84406B	CREAM CUPID HEARTS COAT	8	2010-12-01 08-26-00	2.75	

▼ 4) 결측치 제거

• 'Quantity', 'UnitPrice', 'CustomerID'

```
DF = DF[DF['Quantity'] > 0]
DF = DF[DF['UnitPrice'] > 0]
DF = DF[DF['CustomerID'].notnuII()]
DF.shape
```

(397884, 8)

• 결과 확인

```
DF.isnull().sum(axis = 0)
```

```
InvoiceNo 0
StockCode 0
Description 0
Quantity 0
InvoiceDate 0
UnitPrice 0
CustomerID 0
Country 0
dtype: int64
```

▼ 5) 'United Kingdom' 만 사용

• 대부분의 구매자가 영국국적

```
DF['Country'].value_counts()[:10]
```

United Kingdom 35432

Germany	9040		
France	8341		
EIRE	7236		
Spain	2484		
Nether Lands	2359		
Belgium	2031		
Switzerland	1841		
Portugal	1462		
Australia	1182		
Name: Country,	dtype: int6		

• 영국 데이터만 추출

▼ III. RMF 기반 Data Reengineering

• RECENCY: 가장 최근 상품 구매일에서 오늘까지 기간

• FREQUENCY : 삼품 구매 횟수

• MONETARY VALUE : 총 구매 금액

▼ 1) 'sale_amount' 추가

• '주문 금액' = '주문 개수' * '제품 가격'

```
DF['sale_amount'] = DF['Quantity'] * DF['UnitPrice']

DF.head()
```

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID
0	536365	85123A	WHITE HANGING HEART T- LIGHT HOLDER	6	2010-12-01 08:26:00	2.55	17850.0
1	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00	3.39	17850.0

• 'Customer ID' 정수 변환

```
DF['CustomerID'] = DF['CustomerID'].astype(int)
```

▼ 2) 주문 특성 확인

• Top-5 주문 건수 'Customer ID'

```
DF['CustomerID'].value_counts().head(5)

17841     7847
14096     5111
12748     4595
14606     2700
15311     2379
Name: CustomerID, dtype: int64
```

• Top-5 주문 금액 'Customer ID'

```
DF.groupby('CustomerID')['sale_amount'].sum().sort_values(ascending = False)[:5]
```

• 몇몇 특정 고객이 많은 '주문 건수'와 '주문 금액'을 가지고 있음

▼ 3) 'Customer ID' 기준으로 DataFrame 재구성

- Recency: 'InvoiceDate'의 max()
- Frequency: 'InvoiceNo'♀ count()
- Monetary value : 'sale_amount' □ sum()

- groupby() 결과 Index와 Column 이름 수정
 - o 'Recency', 'Frequency', 'Monetary'

```
DF_CID = DF_CID.reset_index()
```

• RMF 변경 결과

DF_CID.head()

	CustomerID	Recency	Frequency	Monetary
0	12346	2011-01-18 10:01:00	1	77183.60
1	12747	2011-12-07 14:34:00	103	4196.01
2	12748	2011-12-09 12:20:00	4595	33719.73
3	12749	2011-12-06 09:56:00	199	4090.88
4	12820	2011-12-06 15:12:00	59	942.34

▼ 4) 최근 구매일자 Day로 변경

• 오늘 날짜에서 최근 구매날짜('Recency')를 뺀 일자

```
import datetime as dt

DF_CID['Recency'] = dt.datetime(2011, 12, 10) - DF_CID['Recency']

DF_CID['Recency'] = DF_CID['Recency'].apply(lambda x: x.days + 1)
```

• 처리 결과 확인

DF_CID.head()

	CustomerID	Recency	Frequency	Monetary
0	12346	326	1	77183.60
1	12747	3	103	4196.01
2	12748	1	4595	33719.73
3	12749	4	199	4090.88
4	12820	4	59	942.34

▼ 5) Visualization

변수 별 분포 확인

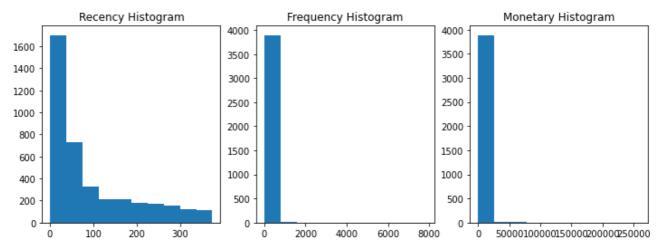
```
fig, (ax1, ax2, ax3) = plt.subplots(figsize = (12, 4), nrows = 1, ncols = 3)
```

```
ax1.set_title('Hecency Histogram')
ax1.hist(DF_CID['Recency'])

ax2.set_title('Frequency Histogram')
ax2.hist(DF_CID['Frequency'])

ax3.set_title('Monetary Histogram')
ax3.hist(DF_CID['Monetary'])

plt.show()
```



▼ IV. K-means Clustering

→ 1) Standardization

• 표준화를 통한 평균과 표준편차 Scaling

DF_CID[['Recency', 'Frequency', 'Monetary']].describe()

	Recency	Frequency	Monetary
count	3920.000000	3920.000000	3920.000000
mean	92.742092	90.388010	1864.385601
std	99.533485	217.808385	7482.817477
min	1.000000	1.000000	3.750000
25%	18.000000	17.000000	300.280000
50%	51.000000	41.000000	652.280000
75%	143.000000	99.250000	1576.585000
max	374.000000	7847.000000	259657.300000

• Scaling 수행

```
from sklearn.preprocessing import StandardScaler

X_input = DF_CID[['Recency', 'Frequency', 'Monetary']].values
X_input_scaled = StandardScaler().fit_transform(X_input)
```

→ 2) Modeling

K-means

→ 3) Silhouette Score

```
from sklearn.metrics import silhouette_score
silhouette_score(X_input_scaled, kmeans.fit_predict(X_input_scaled))
```

0.6114742734112578

#

#

#

The End

#

#

#